생활도로(골목길)에서의 전방 추돌 예측 및 방지 알고리즘

팀장 김찬진

김찬진 20203335
양우영 20223398
엄유빈 20233302
이수홍 20203361

최종 발표

목차

I. 연구 개요

- 연구 배경 및 필요성
- 문제 정의

II. 데이터 및 모델 설계

- 데이터 설명
- 데이터 전처리
- 사용한 인공지능 모델

III. 구현 및 실험 설계

- 구현 방법
- 실험 조건

IV. 결과 분석 및 적용 가능성

- 실험 결과
- 결과 분석
- 자동차 응용 가능성
- 한계점
- 개선 방향
- 결론

V. 참고문헌 및 활용 자료

연구 배경 및 필요성

현황 및 문제점



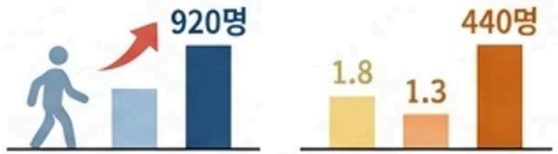
생활도로(골목길):
차도와 보도의 구분이 불명확한 보차혼용 환경,
차량·보행자·PM이 동일 공간 공유

→ 시야 가림, 좁은 도로 폭, 돌발 객체 출현 등이 빈번해 전방 충돌 위험 높음

통계

2024년 보행 중 **사망자 920명**
(전체의 36.5%)

보차혼용도로 보행자 사고
V
보차분리도로 보행자 사고



기존 모델의 한계



- 일반 도로 중심 설계
- 차선 불분명, 복합 개체 혼재한 골목길 한계
- 단순 객체 인식/고정 거리 기준 한계

연구 필요성

생활도로 환경에 특화된 인공지능 기반의 객체 인식 및 위험도 판단 기술 필요

YOLOv8 활용
- **보행자, PM, 차량 검출**
- **객체별 충돌 위험도 표시 알고리즘 개발**

기대효과

- 생활도로 주행 보조
- 저속 자율주행
- 어린이보호구역 안전 시스템

→ 안전 시스템 등에서
전방 추돌 위험을 사전에
예측하고 사고 예방에 기여 가능

문제 정의

성공적인 결과:
생활도로 전방 카메라 영상으로부터 보행자 및 PM, 차량을 검출하고,
객체별 전방 충돌 위험도를 예측하여 Safe/Caution/Danger 단계로 시각화하는 알고리즘 구현

입력 데이터

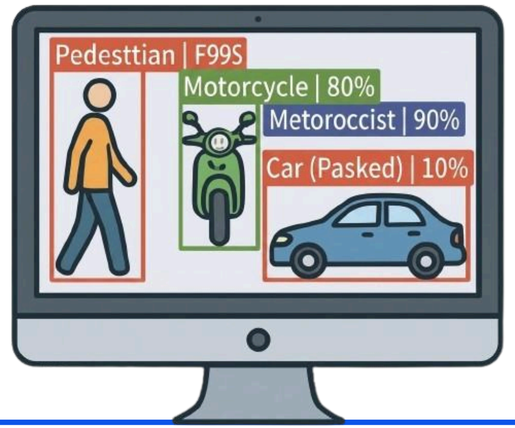
입력 데이터 :
AIHub「생활도로 객체인식 자율주행 데이터」

- **입력 형식:**
  생활도로 전방 카메라 이미지 파일 (.jpg)
- **라벨 형식:**
  객체 위치 및 클래스 정보가 포함된 텍스트 라벨링 파일 (.txt)
- **테스트 입력:**
  이미지 시퀀스 또는 생활도로 주행 영상

출력 결과

출력 결과 : YOLOv8 기반 객체 검출 결과

- 객체 바운딩 박스
- 객체 클래스명
- 객체별 충돌 위험도 표시



문제 유형

검출

- YOLOv8을 활용하여 생활도로 전방 카메라 영상에서 보행자/PM 및 차량 검출

예측

- 검출된 객체의 위치, ROI 충돌 바운더리와의 겹침 정도, 바운딩 박스 면적 변화 등을 기반으로 전방 충돌 위험도 예측

분류

- 예측된 위험도를 기준으로 객체별 위험 수준을 Safe / Caution / Danger 3단계로 분류

데이터 설명

데이터 출처

AIHub「생활도로 객체인식 자율주행 데이터」 생활도로 자율주행 인식 모델 개발을 위한 전방 카메라 기반 객체 인식 데이터

https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=data&dataSetSn=71784

데이터 종류

시간대별, 시나리오별, 도로유형별로 분류된 이미지 데이터
전체 데이터 규모: 약 40만 장
데이터 용량: 약 90GB
전방 카메라 이미지 파일
파일 형식: .png
라벨링 데이터
객체 클래스 및 바운딩 박스 좌표 정보

학습용 데이터 개수

전체 데이터를 모두 학습에 사용하지 않고, 프로젝트 목적에 맞는 일부 프레임 선별

선별 데이터: 5,000장
선별 기준: 중복 프레임 제거, 주/야간 균형 조정, 돌발 상황 우선 표집
집중 도로유형: 보호구역, 보차도로, 일방통행로
선별 비율 보차도로 : 일방통행로 : 보호구역
= 2 : 2 : 1

클래스 종류

YOLOv8 학습 및 충돌 위험도 산정 대상은 **교통약자 및 돌발 객체(보행자, 차량, PM(Personal Mobility))로 한정**

- 보행자: 돌발 진입 가능성이 높은 주요 위험 객체
- PM: 이동 방향 예측이 어렵고 보행자와 유사한 위험도 적용
- 차량: 전방 추돌 및 진행 경로 방해 객체, 직접 충돌 대상이자 시야 가림 및 회피 경로 제한 요소

학습/검증/시험 데이터 분할 방법

전체 이미지 데이터 중 YOLOv8 학습에 활용하기 위해 다음과 같이 분할한다.

- Training data: 5,000 장
- Validation data: 500 장
- Test data: 외부 영상 데이터

데이터 예시 이미지



데이터 전처리

이미지 크기 조정

640×640 resize

라벨 데이터 정규화

절대 좌표계 기반 JSON 데이터를 YOLOv8 모델 학습에 필수적인 상대 비율(정규화) 기반의 TXT 포맷으로 일괄 변환하였다.

데이터 증강

mosaic=1.0
mixup=0.2
hsv_h=0.015
hsv_s=0.7
hsv_v=0.4
degrees=10
translate=0.1
scale=0.5
fliplr=0.5

결측치 처리

이미지와 라벨 파일의 매칭 여부를 확인하고, 누락된 이미지·라벨 파일이나 잘못된 바운딩 박스 좌표를 포함한 데이터를 제외하였다. 이를 통해 결측치 및 비정상 라벨로 인한 학습 오류를 방지하였다.

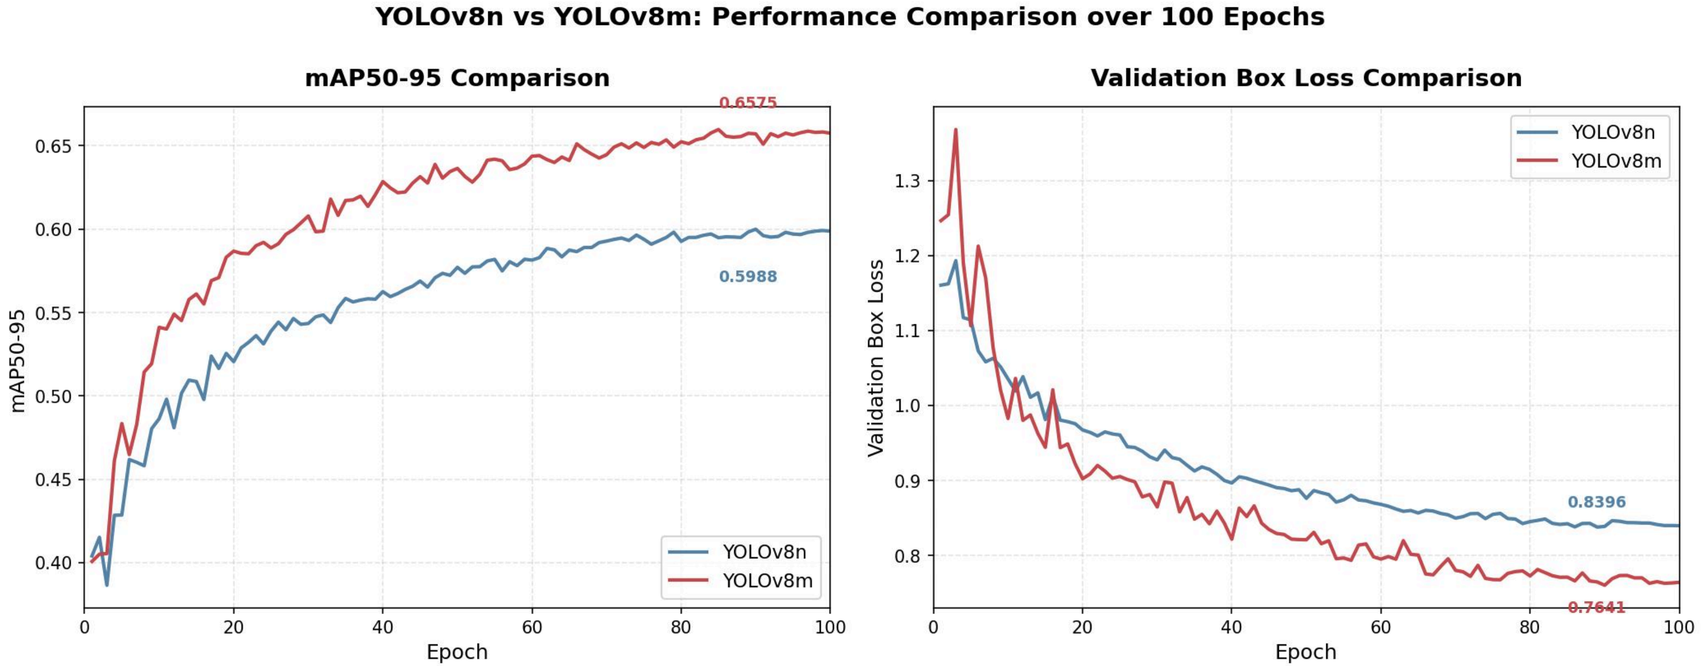
train/validation/test split

선별한 이미지 데이터를 YOLOv8 학습에 활용하기 위해 다음과 같이 분할한다.

- Training data: 5,000 장
- Validation data: 500 장
- Test data: 988장

YOLOv8 학습을 위해 이미지를 640×640으로 조정하고, JSON 라벨을 TXT 형식으로 변환 이후 누락·비정상 데이터를 제거하고 데이터 증강 적용 후, 약 5,000장의 데이터를 학습·검증·시험용으로 분할

사용한 인공지능 모델 - YOLOv8m 채택



1. 면적 팽창률(AER) 산출은 프레임 간 바운딩 박스 크기 변화량에 직접 의존하므로, 박스 좌표의 미세한 떨림(jitter)이 노이즈로 누적된다. 특히 원거리 객체는 점유 픽셀이 적어 동일한 좌표 오차의 상대적 영향이 크므로 정확도가 높은 모델이 요구된다. 본 실험에서 YOLOv8m은 Nano 대비 Validation Box Loss가 약 9.0% 낮게 수렴하여 박스 회귀 성능의 우위를 확인하였다.

2. YOLOv8m은 Nano 대비 백본과 넥의 채널 수와 깊이가 확장되어 객체의 형상과 경계 특징을 풍부하게 표현한다. 이러한 표현력은 mAP50-95 기준 약 9.8%의 성능 개선(0.5988 → 0.6575)으로 나타나, AER 산출의 기반이 되는 탐지 신뢰도 측면에서 Medium 모델이 적합하다고 판단하였다.

사용한 인공지능 모델 - 전체 시스템 파이프라인

Pipeline

1. Input

YOLO 모델 로드
이미지 시퀀스 입력

>

2. ROI 설정

Main ROI (주행경로)
Buffer ROI (측면)

>

3. 객체 추적

YOLOv8
model.track
ID. Box. Class

>

4. Risk 산출

Spatial +
Temporal +
Object Weight

>

5. 판정/시각화

Safe/Caution/
Danger
3단계 출력

1. **입력(Input) :** 시간적 변화(TTC)를 계산하려면 단일 이미지가 아닌 연속된 프레임 시퀀스가 필요하므로 원본 주행 영상에서 초당 10프레임(10 FPS)으로 이미지를 추출하여 입력으로 사용한다.
2. **ROI 설정 :** Main ROI와 Buffer ROI 두 개의 사다리꼴 영역을 설정하고 각 객체의 판정점이 어느 ROI에 속하는지 확인한다. ROI 밖의 객체는 위험도 산출에서 제외되어 불필요한 경고를 억제한다.
3. **객체 검출, 추적 :** 프레임 간 동일 객체에 일관된 ID를 부여하여 시간적 변화(면적 팽창률, 횡방향 이동)를 측정하였다.
4. **Risk 산출 :** ROI 내부 객체에 대해 Spatial Score, Temporal Score, Object Weight를 합산해 0~100점의 정량적 위험도를 산출한다.
5. **출력(시각화) :** 최종 위험도 점수를 Safe(≤40) / Caution(40~79) / Danger(≥80) 3단계로 분류하고, 바운딩 박스 색상(파랑/주황/빨강)과 점수를 영상 위에 실시간 오버레이하여 출력하였다.

구현 방법 - ROI 기반 공간 위험도 산출

1. 이중 ROI 구조(사다리꼴, 원근감 반영)

- **Main ROI :** 자차 주행 경로. 화면 너비 0.3~0.7(밑변), 0.45~0.55(상단)
- **Buffer ROI :** 측면 방어막. 화면 너비 0.2~0.8(밑변), 0.40~0.60(상단)

→ 이아영 외(2022) 논문의 공식에 따라 산출한 이론적 종방향 ROI는 17m이지만, 활용한 데이터는 단안 카메라의 시야각과 설치 높이에 대한 정밀한 데이터가 부재하여 본 프로젝트에서는 화면 높이의 65% 지점을 ROI 상단 경계로 경험적으로 설정하였다. 이는 골목길 환경에서 자차 전방 약 10m 내외의 영역에 해당하며, 골목길 평균 차량 속도(20km/h) 기준 약 1.8초의 안전 확보 시간에 해당한다.

2. 판정점 설정 및 선형 방정식 기반 공간 위험도 점수 부여

$R_{spatial} = 20 + 20 \times (1 - \frac{d}{d_{max}})$ (d : 판정점과 ROI 무게중심 간 거리, d_{max} : ROI 무게중심과 ROI 꼭짓점 간 최대거리)

차량은 박스 하단 중심과 좌·우 측면의 수직 중앙점을, 보행자/PM은 박스 하단 좌·우 꼭짓점을 판정점으로 설정하였다.
이 판정점이 ROI 내부에 위치할 때 공간 위험도 점수를 부여한다.
Main ROI에 진입한 경우, 위 선형 방정식에 따라 기본 20점에서 시작하여 무게중심에 가까워질수록 증가해
최대 40점을 부여한다. Buffer ROI에만 진입한 경우에는 **20점을 고정 부여**한다.

Source : 이아영, 이호준, 이경수, "자율주행 인지 모듈의 실시간 성능을 위한 적응형 관심 영역 판단," 자동차안전학회지, 제14권, 제2호, pp. 20-25, 2022.

구현 방법 - TTC 기반 시간 위험도 산출

1. 면적 팽창률(AER) 기반 TTC 계산

$$TTC = \frac{s}{\dot{s}} = \frac{2}{\frac{\dot{A}}{A}} = \frac{2}{\text{Area Expansion Rate}} \qquad \text{Area Expansion Rate} = \frac{\text{area} - \text{prev_area}}{\text{prev_area}}$$

위 공식을 통해 객체까지의 실제 거리와 초점거리를 모르더라도 화면상 객체 크기 변화만으로 TTC 산출이 가능하다.

2. 객체별 임계값 설정과 비선형 방정식 기반 시간 위험도 점수 부여

ADAS 산업 표준에 기반하여 객체 종류별로 임계값을 차등 적용하였다. **차량**은 FCW(Forward Collision Warning) 기준에 따라 위험 임계값(t_{min})을 **1.5초**로 설정하였고, **보행자/PM**은 Euro NCAP의 교통약자 보호 기준에 따라 **2.5초**로 더 보수적으로 설정하였다. 또한 안전 임계값(t_{max})은 각각 4초와 5초로 설정하여, TTC가 이를 초과하면 0점으로 처리하였다.

$$R_{TTC}(t) = 50 \times \frac{\frac{1}{t} - \frac{1}{t_{max}}}{\frac{1}{t_{min}} - \frac{1}{t_{max}}} \quad (t_{min} < t < t_{max})$$

위 방정식은 TTC의 역수에 비례하는 형태로, 충돌까지 남은 시간이 짧을수록 점수가 가파르게 상승한다.
이를 통해 충돌 임박 구간에서의 민감도를 극대화하면서 안전 구간에서의 불필요한 경고를 억제하였다.

Source : A. Nègre et al., "Real-Time Time-to-Collision from Variation of Intrinsic Scale," Experimental Robotics, Springer, 2008.

구현 방법 - 통합 위험도 산출 및 Edge-Case 처리

1. 최종 위험도 (Total Risk Score)

$$TotalRiskScore = Spatial(40) + Temporal(50) + Weight(10)$$

- **Spatial** : Main ROI 무게중심 근접도 (20~40점 연속) / Buffer ROI 진입 시 20점
- **Temporal** : 비선형 TTC 점수 (차량은 Main ROI 밖이면 0점 처리)
- **Weight** : 객체별 가중치. 차량 0점 / 보행자·PM 10점

→ **판정기준 : Danger ≥ 80 / Caution 41~79 / Safe ≤ 40**

2. Edge-Case 처리

- **Ego-Turn 무시 :** 자차 회전 시 횡방향 이동 폭이 화면 너비 10% 초과 시
  회전에 의한 휩쓰림으로 판단하여 위험도 80% 삭감
- **객체 이동 궤적 분석 :** 주행 경로 밖으로 멀어지는 객체(Pass-By)는 점수 40% 삭감,
  내 차로를 향해 파고드는 객체(Cut-In)는 위험 점수 유지

실험 조건

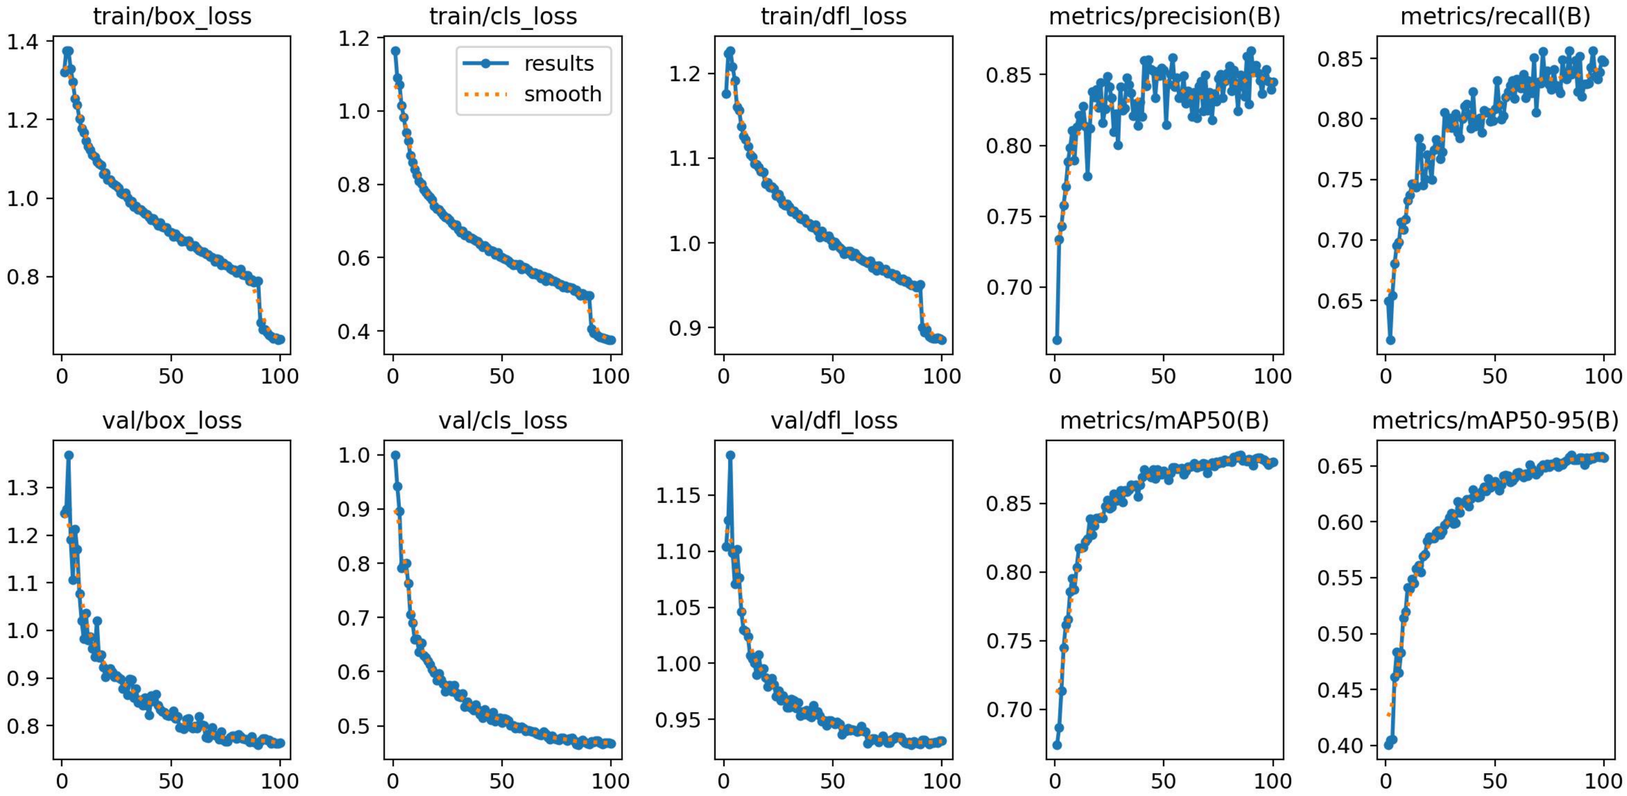
1. 데이터셋 구축 및 전처리

- AI Hub '생활도로 객체인식 자율주행 데이터' 중 전방(Front) 가시광 이미지 활용
- 원본 JSON 포맷의 라벨링 데이터를 YOLOv8 학습용 텍스트 포맷(.txt) 정규화 좌표로 일괄 변환하는 파이썬 전처리 자동화 스크립트 직접 구현
- 충돌 예측 목적에 부합하도록 유사 클래스를 병합하여 차량(Vehicle), 보행자(Pedestrian), 개인형 이동장치(PM) 3가지 주요 클래스로 학습 데이터를 최적화

2. 학습(Training) 환경

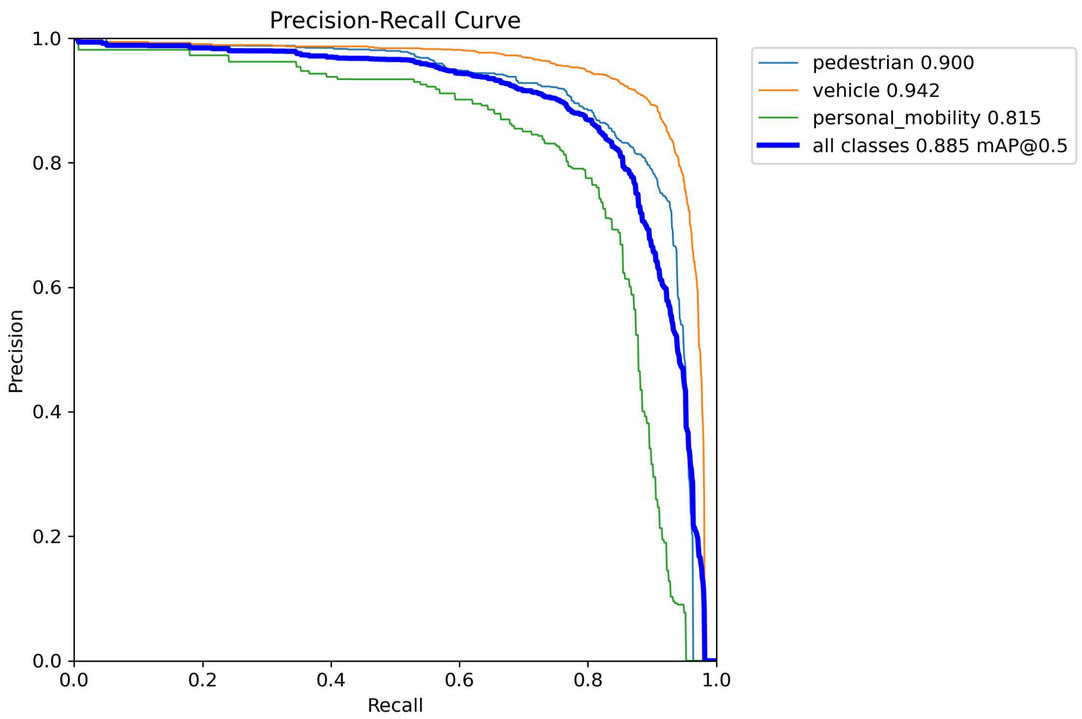
- 학습 환경: RTX 3060 GPU가 탑재된 데스크탑 PC 환경을 통해 제한된 시간 내 효율적인 파인튜닝 수행
- 추론 및 디버깅 환경: 도출된 최적 가중치(best.pt)를 로컬 PC(VS Code)로 이식하여 비디오 스트림 실시간 분석 및 UI 표출 검증
- 하이퍼파라미터: FPS = 10 (초당 프레임 수), FRAME_INTERVAL = 10 (비교 윈도우 프레임 수) 적용

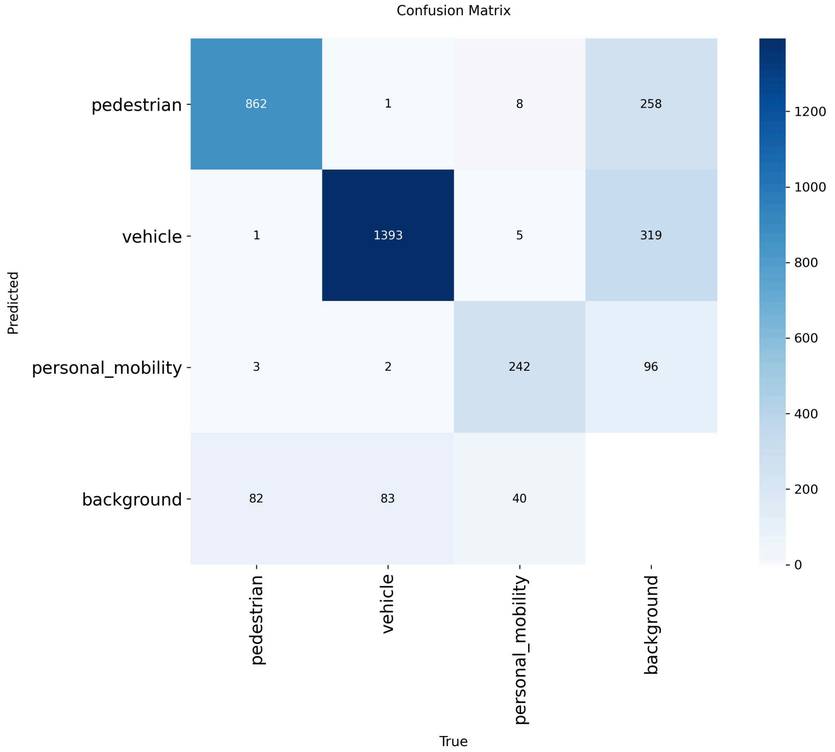
실험 결과



학습 횟수 증가에 따라 train loss들이 감소하는 것을 볼 수 있다.
또한 validation loss도 감소하여 모델이 데이터에 안정적으로 수렴함을 알 수 있다.
Precision은 약 0.85, Recall은 약 0.84 수준까지 증가하였다.
mAP@50은 최종적으로 약 0.88, mAP@50-95는 약 0.66 수준에 도달하여 비교적 높은 객체 검출 성능을 보였다.

실험 결과





vehicle 클래스의 AP가 약 0.942로 가장 높은 성능을 기록하였다. pedestrian 클래스는 약 0.900으로 안정적인 검출 성능을 보였다. personal_mobility 클래스는 약 0.815로 상대적으로 낮은 성능을 보였으며, 다른 클래스 대비 오분류가 발생하였다.

일부 pedestrian 및 vehicle 객체가 background로 분류되는 경우가 존재하여 작은 객체 또는 불명확한 객체에서 미검출이 발생한 것으로 보인다. personal_mobility 클래스는 데이터 수 부족이나 객체 형태 유사성으로 인해 다른 클래스 및 background와 혼동되는 경향이 나타났다.

실험 결과

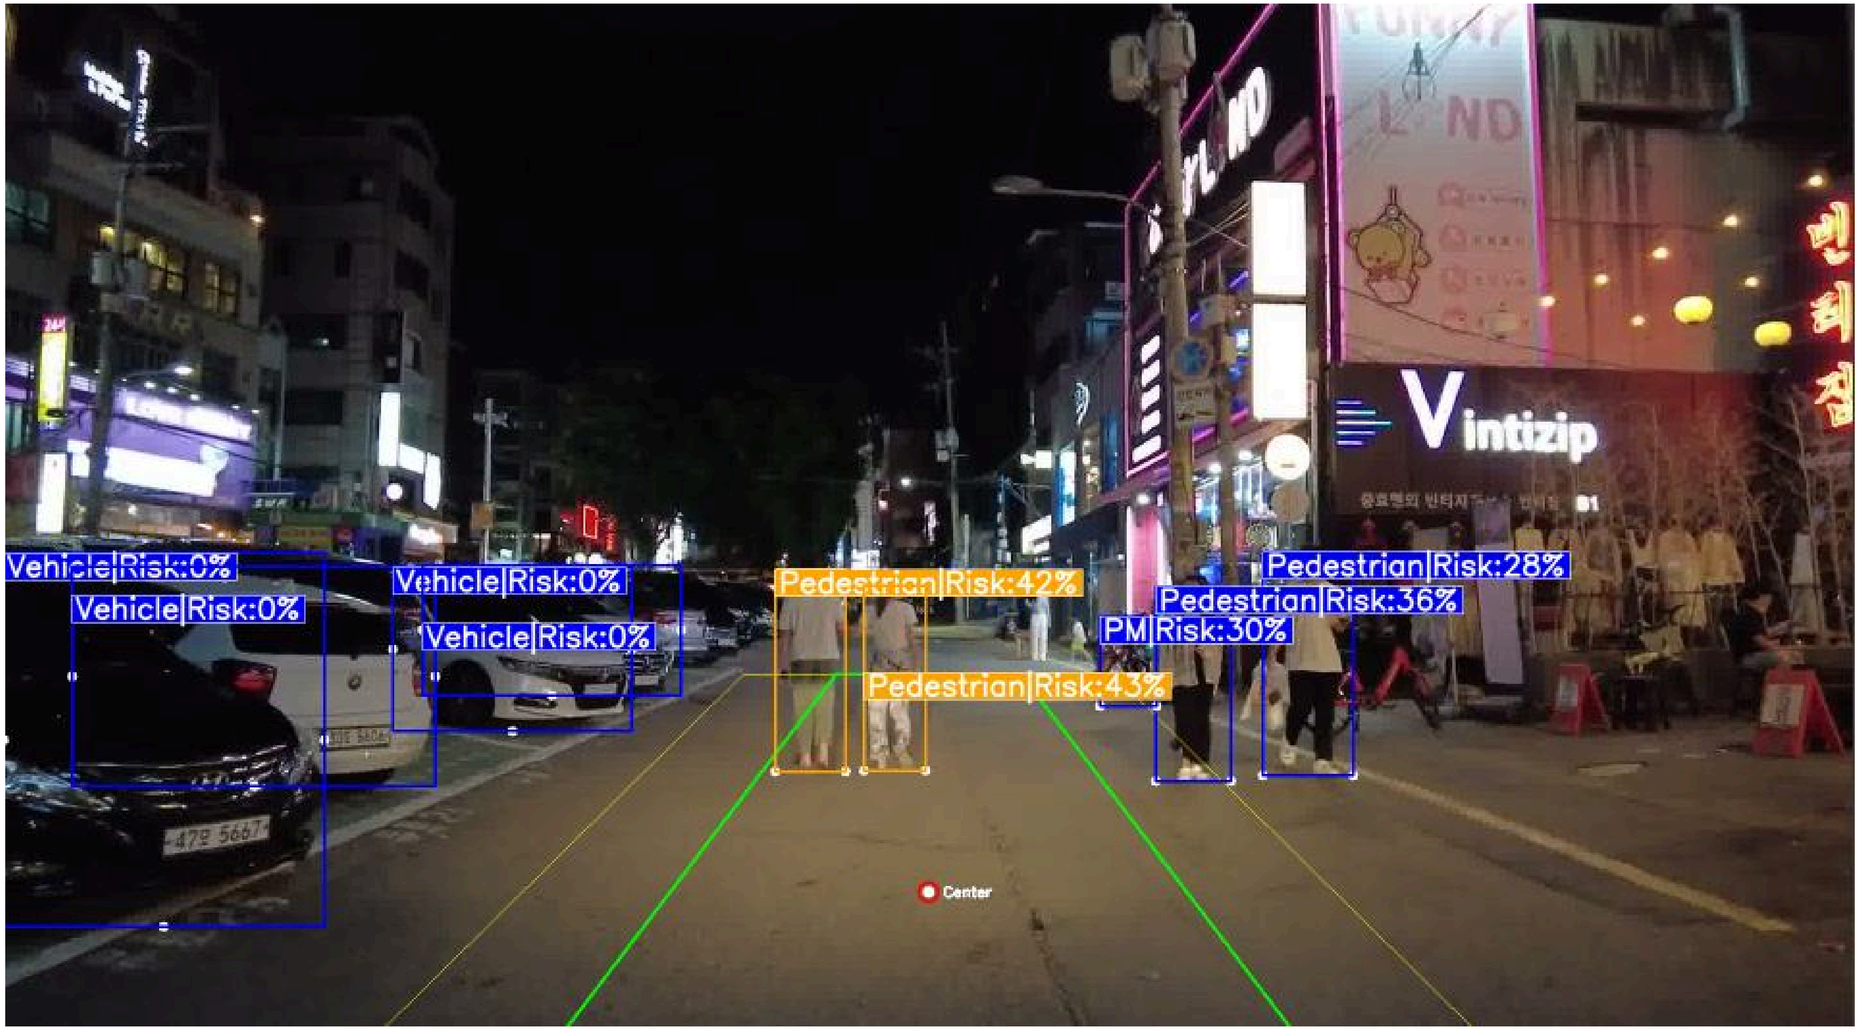
검증 자료

학습 결과



차량과 보행자에 대한 인식은 대체적으로 잘 되는 모습을 보인다.
하지만 퍼스널 모빌리티에 사람이 타고 있는 경우 보행자로 인식되어 오분류가 발생하기도 하며 퍼스널 모빌리티 자체를 인식하지 못하는 경우도 보인다.

결과 분석



코드 실행 결과 영상 링크 : https://youtu.be/wLBMDQt-mto

결과 분석

기존 YOLOv8m 모델보다 객체 인식률에서 더 나은 성능을 보이지만 인식 도중 객체를 놓치는 현상이 발견됨,
킥보드나 자전거에 탄 사람의 뒷모습을 보행자로 인식함.
→ 골목길에서의 데이터셋을 학습시켰으므로 목표 객체에 대한 인식률이 높고 보행자 인식에서 가끔 객체인식 오류가
나는 현상은 객체인식 기술의 한계라 생각하고 해결을 위해서 다양한 보행자 데이터셋을 활용하는 수 밖에 없다 판단함.

객체가 제대로 인식되는 상황에서는 의도한 대로 위험률과 상태가 계산됨.
→ 알고리즘 작성 과정에서 코드 구성이 정상적으로 이루어졌음.

밝기가 어두운 야간 상황에서도 낮 주행 상황과 비슷하게 객체가 대체로 정확하게 인식됨.
→ 강화학습을 추가하여 악조건에서도 객체 인식 성능이 준수하게 나옴.

오르막길이나 내리막길에서 roi 구역 변화가 없기 때문에 정확한 판정이 어려움.
→ 유동적인 roi 구역 설정방법 개발 필요.

차량 회전에 대한 정보가 없어 정지한 객체에 대해서 과도하게 높은 점수를 부과하는 오류가 있음.
→ 현재 이미지만을 데이터로 사용하기 때문에 위 문제를 해결하기 위해서는 자동차 자체의 조향각이나 시속 등의
정보를 얻을 수 있으면 더욱 발전가능.

자동차 응용 가능성





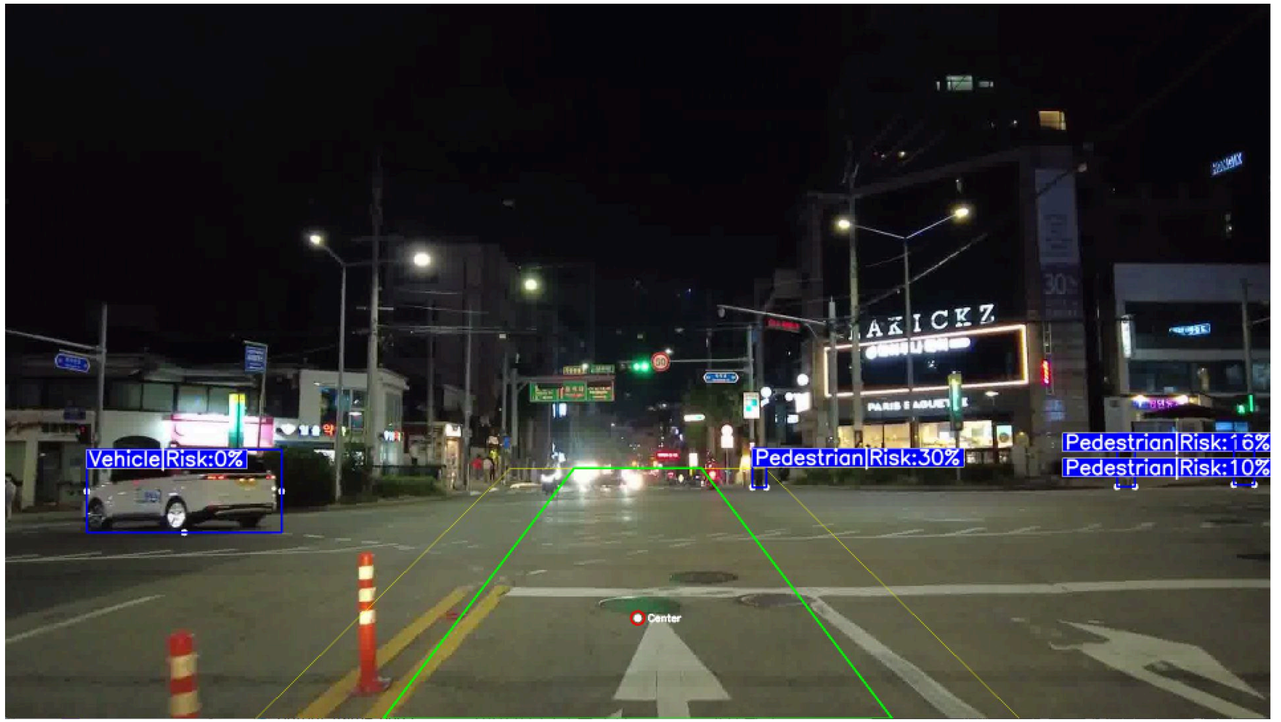


- **생활도로(골목길) 특화형 초저가 ADAS 솔루션**
  고가의 고정형 센서없이
  단일 전방 카메라만으로 구현 가능.

- **교통약자 돌발 사고 방지 고도화**
  보행자 및 PM 특화된 알고리즘 적용.
  저연산, 고효율 돌발 진입 조기 경보 가능.

- **다양한 모빌리티 플랫폼으로의 확장**
  전동 킥보드, 배달용 로봇 등
  소형 모빌리티의 안전 보조장치 응용 가능.

한계점



- **바운딩 박스 떨림(Jitter)으로 인한 시간적 점수 노이즈**
  2D 객체인식 모델 특성상 프레임별 바운딩 박스의 미세한 크기 변화 발생
- **경사로 주행 시 고정 ROI 매핑**
  오르막 주행 시 2D 화면상 고정된 사다리꼴 ROI가 하늘을 향하게 되어(노면 이탈),
  실제 전방 객체가 ROI 영역 밖으로 인식되는 미탐(False Negative) 현상 발생.
- **학습 데이터셋 편향에 따른 객체 인식률 저하**
  기존 데이터셋은 동일 차량의 촬영이 아님, 차량마다 높이 블랙박스 위치 등 차이로 인한 ROI 범위, 각도가 일정치 않음

개선 방향

- **곡선 궤적에서의 2D 면적팽창률 적용 한계**
  - 단안 카메라의 태생적 제약으로, Z축 변화없이 회전만 하는 객체의 Bounding Box 면적 변화량이 불규칙하게 산출됨.
  - 직진 도로에 최적화된 현재 알고리즘으로는 교차로 회전 차량의 충돌 예상 시간을 정확히 산출하는데 한계가 존재함.



- **궤적 예측 기반의 하이브리드 필터링**
  - Bounding Box의 중심점 이동벡터를 추적하여 객체가 직진 팽창 중인지 단순 회전 중인지 분류하는 로직 연구 진행중.
  - 카메라 단인 센서의 한계를 보완하기 위해 차량의 횡방향 가속도 데이터 등과 융합하는 방안 모색 중.

개선 방향

- **급경사 주행시 생기는 차체 피치 거동 보상**
  - 골목길에 다수 존재하는 경사 구간 진입 시,
    차체 들림 현상으로 인해 카메라의 피지 각도가 크게 변화함.
  - 특히 내리막 보다 오르막 구간 진입 시 카메라 피치각 상향으로 ROI 오정렬 상황 발생.

- **IMU 연동 기반 동적 ROI 보정**
  - 차량 또는 기기의 IMU(관성측정장치) 센서 데이터를 활용,
    차량의 상하 기울기 변화량을 실시간 산출.
  - 노면 경사도에 따라 사다리꼴 ROI의 Y축 위치를 능동적으로 보상하여 추적하는
    동적 매핑 알고리즘의 도입 필요성.

개선 방향

- **다중 객체 밀집 시 UI 정보 과부하**
  - 좁은 골목길 환경 특성상 보행자, PM, 차량 등 다수의 객체가 동시다발적으로 인식됨.
  - 현재 객체명, Risk Score 수치 등 텍스트 정보가 과다하게 표출되어,
    운전자의 직관적인 상황 인지 저해함.

- **운전자 인지 부하 최소화를 위한 UI 간략화**
  - 텍스트 정보 최소화 및 위험도 상태 표시 간소화.
  - 안전 범위 객체는 바운딩 박스만 표출하고 주의/위험 객체에만
    시각적 경고 및 Risk Score를 강조 표출하는 선택적 렌더링 도입

결론

단일 카메라의 물리적 제약 극복 및 알고리즘 정립

- 3D 깊이(Depth) 센서 부재라는 하드웨어적 한계를 '시각적 팽창(Optical Expansion)' 원리와 면적팽창률 수식을 통해 극복
- 생활도로 환경 맞춤형 적응형 관심 영역(Adaptive ROI) 설계
- 저속·복잡한 골목길 주행 특성에 맞춰 '짧고 넓은 사다리꼴 형태'로 ROI 재설계
- 불필요한 외곽 데이터 연산을 최소화하여 자율주행 인지 모듈의 필수 조건인 실시간 처리 성능(Real-time Performance) 확보
- 독자적인 통합 충돌 위험도 산출 프레임워크 완성
- 공간적 위협(Spatial), 시간적 임박성(Temporal), 교통약자 가중치(Weight)를 결합한 Total Risk Score(0~100%) 산출 로직 개발
- 산업 표준 임계값을 반영한 3단계(Safe / Caution / Danger) 시각화 UI를 통해 실효성 있는 선제적 경보 시스템 구현

기대효과

- 저연산·고효율 인지 소프트웨어를 통해 센서 단가를 낮추고, 보행자 및 퍼스널 모빌리티(PM) 등 교통약자 보호를 위한 ADAS 기술의 범용적 상용화 가능성 입증.

참고문헌

- Ultralytics, "YOLOv8," GitHub, 2023. https://github.com/ultralytics/ultralytics
- 이아영, 이호준, 이경수, "자율주행 인지 모듈의 실시간 성능을 위한 적응형 관심 영역 판단," 자동차안전학회지, 제14권, 제2호, pp. 20-25, 2022.
- A. Nègre et al., "Real-Time Time-to-Collision from Variation of Intrinsic Scale," Experimental Robotics, Springer, 2008.
- AI Hub, "생활도로 객체인식 자율주행 데이터", 한국지능정보사회진흥원(NIA), 2023.
- Euro NCAP, "AEB/LSS VRU Test Protocol v4.0.0," 2023; ISO 15623:2013, "Forward Vehicle Collision Warning Systems," ISO, 2013.

역할 분담

Main R&R

- 김찬진(팀장) : YOLOv8 모델 기반 딥러닝 객체 인식(차량, 보행자, PM)
  적용 및 인지 성능 테스트, 최종 결과 영상 제작, 발표, PPT 제작
- 양우영 : ROI 크기 정의 관련 논문 분석, 시스템 한계점과 개선 방향 분석, PPT 제작
- 엄유빈 : 면적팽창률을 활용한 속도 측정 논문/자료조사, 발표자료 제작 및 자료 레이아웃 구성
- 이수홍 : 사용 모델 및 데이터 탐색, 알고리즘 코드 작성, 면적 팽창률과 TTC 변환 관련 논문 분석, PPT 제작

또한, 매주 2회 오프라인 공동 작업으로 알고리즘 수정 및 보완, 아이디어 공유, 발표자료 제작 진행

최종자료 제작 R&R

- 김찬진(팀장) : 실험 결과, 결과 분석 파트
- 양우영 : 자동차 응용 가능성, 한계점, 개선 방향, 결론, 참고문헌 파트
- 엄유빈 : 표지, 연구배경 및 필요성, 문제 정의, 데이터 설명, 데이터 전처리 파트, 전체 레이아웃 수정
- 이수홍 : 사용한 인공지능 모델, 구현 방법, 실험 조건 파트

감사합니다.